

**REKA CIPTA PEMANFAATAN RESNET-2D DALAM
PENERJEMAHAN BAHASA ISYARAT INDONESIA (BISINDO)
BERBASIS LANDMARK MEDIAPIPE**

TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di
Program Studi Teknik Informatika, Fakultas Teknologi Industri,
Institut Teknologi Sumatera

Oleh:

Sikah Nubuahtul Ilmi

122140208



ITERA

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	v
DAFTAR GAMBAR	vi
DAFTAR RUMUS	vii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	5
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	6
BAB II TINJAUAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.2 Dasar Teori	13
2.2.1 Bahasa Isyarat Indonesia (BISINDO)	14
2.2.2 <i>Sign Language Recognition</i> (SLR)	14
2.2.3 <i>Isolated Sign Language Recognition</i>	15
2.2.4 <i>MediaPipe Holistic</i>	16
2.2.5 Representasi <i>Landmark</i> sebagai Struktur Spasial <i>Landmark Multichannel</i>	20
2.2.5.1 Koordinat <i>Landmark</i> MediaPipe	20
2.2.5.2 Pengodean Dinamika Gerakan Antar-Frame	21
2.2.5.3 Struktur Tensor Masukan CNN	22
2.2.6 <i>Convolutional Neural Network</i> (CNN) 2D	22

2.2.7	<i>Residual Network (ResNet)</i>	24
2.2.8	Modifikasi Input Channel pada CNN	26
2.2.8.1	CNN Tidak Terbatas pada Input RGB	26
2.2.8.2	Penerimaan <i>Arbitrary Number of Channels</i>	27
2.2.8.3	Contoh Penerapan CNN pada Data Non-RGB	28
2.2.9	Metrik Evaluasi Klasifikasi	28
2.2.9.1	<i>Confusion Matrix</i>	28
2.2.9.2	<i>Accuracy</i>	29
2.2.9.3	<i>Precision</i>	29
2.2.9.4	<i>Recall</i>	30
2.2.9.5	<i>F1-Score</i>	30
BAB III	METODE PENELITIAN	31
3.1	Alur Penelitian	31
3.2	Penjabaran Langkah Penelitian	32
3.2.1	Identifikasi Masalah dan Studi Literatur	32
3.2.2	Pengumpulan Dataset	32
3.2.3	Akuisisi Video Bahasa Isyarat	33
3.2.4	<i>Preprocessing</i> Data	33
3.2.4.1	Augmentasi Resolusi Video	33
3.2.4.2	Ekstraksi <i>Landmark MediaPipe Holistic</i>	33
3.2.4.3	Seleksi <i>Landmark</i>	33
3.2.5	Rekayasa Fitur (<i>Feature Engineering</i>)	34
3.2.5.1	Perhitungan Perubahan Antar-Frame	34
3.2.5.2	Representasi <i>Landmark Multichannel</i>	34
3.2.6	Penyusunan Tensor Masukan CNN	35
3.2.7	Konfigurasi Model dan <i>Hyperparameter</i>	35
3.2.7.1	Arsitektur ResNet-2D	35
3.2.7.2	Modifikasi Input <i>Channel</i>	35

3.2.7.3	Konfigurasi <i>Hyperparameter</i>	35
3.3	Alat dan Bahan	35
3.3.1	Alat.....	35
3.3.2	Bahan.....	36
3.4	Metode Evaluasi	36
3.4.1	Metrik Evaluasi	36
3.4.2	Prosedur Pengujian.....	36
3.5	Ilustrasi Proses Pengolahan Data.....	36
3.5.1	Ilustrasi Input Video.....	36
3.5.2	Ilustrasi Ekstraksi <i>Landmark</i>	36
3.5.3	Ilustrasi Pembentukan Tensor.....	36
DAFTAR PUSTAKA.....		37
LAMPIRAN.....		42

DAFTAR TABEL

Tabel 2.1	Literasi Penelitian Terdahulu.....	10
Tabel 2.2	Perbandingan varian arsitektur <i>Residual Network</i>	26
Tabel 3.1	Ilustrasi representasi fitur <i>landmark multichannel</i> untuk satu <i>landmark</i> sepanjang waktu	34

DAFTAR GAMBAR

Gambar 2.1	Taksonomi pendekatan <i>deep learning</i> dalam SLR	15
Gambar 2.2	Diagram 33 <i>Landmark</i> MediaPipe Pose	18
Gambar 2.3	Ilustrasi 21 titik <i>landmark</i> tangan pada MediaPipe	18
Gambar 2.4	Ilustrasi 468 titik <i>landmark</i> wajah pada MediaPipe	19
Gambar 2.5	Arsitektur dasar CNN dua dimensi	23
Gambar 2.6	Arsitektur umum <i>Residual Network</i> (ResNet)	24
Gambar 2.7	Struktur blok residual pada <i>Residual Network</i> (ResNet) . .	25
Gambar 3.1	Tahap Identifikasi Masalah Hingga Rekayasa Fitur	31
Gambar 3.2	Tahap Penyusunan Tensor Hingga Hasil dan Kesimpulan	32

DAFTAR RUMUS

Rumus 2.1	Perubahan posisi <i>landmark</i> antar-frame	21
Rumus 2.2	Struktur tensor masukan <i>landmark multichannel</i>	22
Rumus 2.3	Operasi konvolusi dua dimensi	23
Rumus 2.4	Perhitungan <i>Accuracy</i>	29
Rumus 2.5	Perhitungan <i>Precision</i>	29
Rumus 2.6	Perhitungan <i>Recall</i>	30
Rumus 2.7	Perhitungan <i>F1-score</i>	30

BAB I

PENDAHULUAN

1.1 Latar Belakang

Teman Tuli atau difabel pendengaran di Indonesia umumnya menggunakan bahasa isyarat sebagai alat komunikasi. Dua bahasa tersebut adalah Sistem Bahasa Isyarat Indonesia (SIBI) dan Bahasa Isyarat Indonesia (BISINDO) [1, 2]. SIBI lebih umum digunakan pada kegiatan formal dan akademis karena dibuat oleh pemerintah dan orang dengar dengan mengadaptasi sistem bahasa isyarat Amerika (*American Sign Language* (ASL)) [3]. Sementara itu, BISINDO lebih umum digunakan untuk percakapan sehari-hari karena merupakan bahasa yang lahir secara alami dari komunitas tuli [3, 4]. Namun, keterbatasan pemahaman BISINDO masih menjadi masalah bagi masyarakat umum dalam berkomunikasi dengan Teman Tuli [5, 6], sehingga dibutuhkan pemanfaatan teknologi untuk mendukung proses penerjemahan bahasa isyarat secara efektif.

Berkembangnya teknologi *computer vision* dan kecerdasan buatan kemudian menginspirasi berbagai penelitian untuk merancang sistem penerjemahan bahasa isyarat ke dalam bentuk teks maupun suara [7, 8]. Pendekatan berbasis *deep learning* menjadi metode yang dominan karena kemampuannya dalam mempelajari pola kompleks dari data visual maupun data berurutan, seperti citra dan video bahasa isyarat. Beberapa penelitian menunjukkan bahwa model *deep learning* mampu mencapai performa yang tinggi dalam pengenalan gerakan bahasa isyarat. Sebagai contoh, Anturkar et al. [9] membandingkan model *Long Short-Term Memory* (LSTM) dan *3D Convolutional Neural Network* (3D CNN) pada dataset video berbasis *landmark* dan melaporkan bahwa model 3D CNN mampu mencapai akurasi sebesar 92,4%. Penelitian lain mengombinasikan CNN dan LSTM berbasis mekanisme

attention untuk pengenalan bahasa isyarat tingkat kata dan memperoleh akurasi sebesar 84,65% pada dataset *American Sign Language* [10]. Selain itu, salah satu penelitian di Indonesia juga menunjukkan pemanfaatan model *deep learning* berbasis LSTM dan GRU untuk klasifikasi BISINDO dengan akurasi mencapai 83% [11].

Sayangnya, pemanfaatan model *deep learning* dalam penerjemahan bahasa isyarat seperti BISINDO hingga saat ini masih didominasi oleh pendekatan berbasis temporal [9, 11–13]. Pendekatan ini menempatkan dimensi waktu sebagai komponen utama dalam pemodelan bahasa isyarat, mengingat gerakan tangan, ekspresi tubuh, serta transisi antar gerakan bersifat berurutan dan saling bergantung secara temporal. Meskipun pendekatan berbasis temporal menunjukkan performa yang baik, sejumlah studi melaporkan bahwa model-model tersebut cenderung memiliki kompleksitas pelatihan yang tinggi serta sensitif terhadap panjang dan kualitas urutan data, terutama pada pemodelan video dengan dinamika temporal yang kompleks [14, 15]. Selain itu, kebutuhan data yang relatif besar serta biaya komputasi yang tinggi sering kali menjadi kendala dalam penerapan model temporal, khususnya pada skenario dengan keterbatasan data atau sumber daya komputasi [16, 17]. Berdasarkan konteks tersebut, pemanfaatan model berbasis spasial seperti *Convolutional Neural Network* (CNN) atau ResNet dalam klasifikasi bahasa isyarat dengan dataset temporal masih relatif terbatas.

Terbatas pada beberapa studi, pendekatan spasial dalam klasifikasi bahasa isyarat umumnya diterapkan pada pemodelan frame tunggal atau citra hasil ekstraksi video, yang banyak digunakan pada tugas pengenalan alfabet atau angka isyarat. Sebagai contoh, penelitian oleh Sholawati [18] memanfaatkan citra digital untuk klasifikasi abjad SIBI menggunakan CNN. Penelitian serupa juga dilakukan oleh Saputra et al. [19] yang menerapkan CNN untuk klasifikasi abjad dan huruf BISINDO menggunakan dataset citra statis. Padahal, bahasa isyarat yang digunakan dalam komunikasi sehari-hari memiliki struktur yang

jauh lebih kompleks karena tersusun atas rangkaian gerakan dinamis yang berlangsung secara berurutan dalam dimensi waktu.

Beberapa penelitian di luar konteks BISINDO menunjukkan bahwa model berbasis spasial memiliki potensi yang kuat untuk menangani data yang bersifat temporal apabila representasi datanya dirancang secara tepat. Sebagai contoh, Zhu et al. [20] mengusulkan *Fully 2D Convolutional Network* (F2DCNet) untuk tugas *continuous sign language recognition*. Beberapa studi lain pada domain pengenalan aksi manusia (*action recognition*) juga menunjukkan bahwa strategi representasi *input* dapat membantu jaringan konvolusional dua dimensi untuk menangkap informasi temporal. Kim et al. [21] memperkenalkan strategi *channel sampling* untuk menyusun ulang kanal input sehingga variasi temporal antar frame dapat ditangkap oleh backbone 2D tanpa memerlukan konvolusi tiga dimensi yang berat. Bilen et al. [22] merangkum seluruh video menjadi sebuah *dynamic image* tunggal menggunakan mekanisme pooling terurut sehingga video tersebut dapat diproses layaknya citra oleh CNN dua dimensi. Selain itu, Wang et al. [23] mengusulkan *Temporal Segment Networks* yang menggunakan pengambilan sampel temporal secara *spars* dan agregasi prediksi untuk menghasilkan representasi video-level pada jaringan CNN 2D. Temuan-temuan tersebut menunjukkan bahwa rekayasa representasi input atau strategi sampling temporal dapat memperkaya kemampuan model spasial dalam mendeteksi pola gerakan temporal. Memanfaatkan prinsip yang serupa, penelitian ini menyusun *landmark* tubuh manusia ke dalam struktur dua dimensi sebagai *pseudo-image* agar dapat diproses oleh ResNet-2D untuk klasifikasi BISINDO.

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk mengeksplorasi potensi penggunaan model ResNet-2D dalam klasifikasi dan penerjemahan bahasa isyarat Indonesia (BISINDO) berbasis *landmark* tubuh manusia. Berbeda dari mayoritas penelitian sebelumnya yang menitikberatkan pada pemodelan temporal eksplisit, penelitian ini menyusun data *landmark*

tubuh manusia ke dalam representasi dua dimensi sebagai *pseudo-image* agar dapat diproses oleh jaringan konvolusional dua dimensi. Selain itu, penelitian ini menganalisis pengaruh variasi representasi input *landmark* terhadap performa model dalam mengenali pola gerakan bahasa isyarat. Melalui pendekatan ini, diharapkan penelitian dapat memberikan pemahaman mengenai sejauh mana model spasial ResNet-2D mampu menangkap informasi gerakan bahasa isyarat yang bersifat temporal, khususnya pada konteks bahasa isyarat lokal seperti BISINDO.

1.2 Rumusan Masalah

Dominasi pendekatan berbasis temporal dalam penelitian penerjemahan bahasa isyarat menimbulkan keterbatasan pemahaman mengenai potensi pendekatan alternatif yang lebih ringan dan berbasis spasial. Berdasarkan konteks tersebut, belum banyak penelitian yang mengkaji sejauh mana model spasial berbasis *Convolutional Neural Network* dua dimensi, khususnya arsitektur ResNet-2D, mampu menangkap pola gerakan bahasa isyarat ketika data direpresentasikan dalam bentuk struktur dua dimensi dari *landmark* tubuh manusia. Selain itu, pengaruh variasi kombinasi *landmark* tubuh terhadap performa model spasial dalam klasifikasi gerakan Bahasa Isyarat Indonesia (BISINDO) juga belum banyak dieksplorasi secara sistematis.

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan di atas, maka tujuan dari penelitian ini adalah:

1. Menilai kelayakan penggunaan model spasial berbasis *Residual Network* (ResNet-2D) dalam klasifikasi gerakan Bahasa Isyarat Indonesia (BISINDO) berbasis *landmark*.
2. Mengkaji pengaruh variasi kombinasi *landmark* MediaPipe (pose, tangan, dan wajah) terhadap performa model ResNet-2D.

3. Mengevaluasi performa model menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, serta *Confusion Matrix*.

1.4 Batasan Masalah

Adapun batasan masalah dari penelitian ini agar sesuai dengan yang diharapkan adalah sebagai berikut:

1. Bahasa isyarat yang digunakan adalah Bahasa Isyarat Indonesia (BISINDO) dengan lingkup cakupan wilayah Jawa Barat.
2. Jumlah kelas kata yang dijadikan label dibatasi pada 10 kata dasar BISINDO yang umum digunakan dalam percakapan sehari-hari.
3. Model utama yang digunakan adalah model spasial berbasis *Residual Network* (ResNet-2D)
4. Model *Convolutional Neural Network* (CNN) digunakan sebagai model pembandingan (baseline) untuk memberikan konteks performa terhadap model ResNet-2D.

1.5 Manfaat Penelitian

Adapun manfaat yang diperoleh dari hasil penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi pengetahuan terkait pemanfaatan model spasial berbasis *Residual Network* dalam klasifikasi gerakan BISINDO berbasis *landmark* MediaPipe.
2. Memberikan gambaran empiris mengenai pengaruh kombinasi *landmark* tubuh (pose, tangan, dan wajah) terhadap performa model spasial dalam pengenalan bahasa isyarat.
3. Menjadi referensi bagi penelitian selanjutnya yang ingin mengeksplorasi pendekatan spasial dalam pengolahan data gerakan atau *action recognition* berbasis data berurutan atau temporal.
4. Menjadi bahan evaluasi dan pembelajaran tambahan dalam penerapan

model *deep learning* untuk pengenalan pola gerakan berbasis titik koordinat.

1.6 Sistematika Penulisan

Penulisan tugas akhir ini disusun secara sistematis ke dalam lima bab untuk memudahkan pemahaman terhadap alur dan substansi penelitian. Adapun sistematika penulisan penelitian ini dijelaskan sebagai berikut.

Bab I Pendahuluan

Bab ini memuat latar belakang penelitian, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan tugas akhir.

Bab II Tinjauan Pustaka

Bab ini membahas penelitian-penelitian terdahulu yang relevan dengan topik penelitian, serta menguraikan landasan teori yang mendukung konsep dan metode yang digunakan dalam penelitian.

Bab III Metodologi Penelitian

Bab ini menjelaskan tahapan dan alur kerja penelitian, meliputi teknik pengumpulan dan pengolahan data, perancangan model yang digunakan, serta metode evaluasi performa model.

Bab IV Hasil dan Pembahasan

Bab ini menyajikan hasil implementasi dan pengujian model yang telah dilakukan, disertai dengan analisis dan pembahasan terhadap hasil yang diperoleh.

Bab V Kesimpulan dan Saran

Bab ini memuat kesimpulan yang diperoleh dari hasil penelitian serta saran untuk pengembangan dan penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian ini berangkat dari berbagai penelitian terdahulu yang membahas pengenalan bahasa isyarat (*sign language recognition*) sebagai bagian dari pengenalan pola gerakan berbasis visual. Penelitian-penelitian tersebut menunjukkan beragam pendekatan dalam memodelkan bahasa isyarat, baik dari sisi jenis bahasa isyarat yang dikenali maupun strategi pemodelan data gerakan. Secara umum, pendekatan yang digunakan dapat diklasifikasikan berdasarkan cara memanfaatkan informasi temporal dan spasial dalam representasi data. Tinjauan pustaka pada bagian ini disusun untuk mengkaji penelitian-penelitian yang relevan sebagai bahan perbandingan serta dasar dalam mengidentifikasi celah penelitian. Uraian selanjutnya akan membahas beberapa penelitian terdahulu yang berkaitan dengan pengenalan bahasa isyarat, dimulai dari pendekatan berbasis temporal yang masih banyak digunakan hingga eksplorasi pendekatan berbasis spasial.

Salah satu pendekatan awal yang banyak digunakan dalam pengenalan bahasa isyarat adalah pemodelan berbasis informasi temporal dari rangkaian gerakan. Penelitian yang dilakukan oleh Yoses (2023) merepresentasikan pendekatan ini melalui pengenalan Bahasa Isyarat Indonesia (BISINDO) dengan memanfaatkan model sekuensial LSTM dan GRU. Informasi gerakan diekstraksi dalam bentuk landmark tangan, tubuh, dan wajah menggunakan MediaPipe Holistic, kemudian dipelajari sebagai urutan waktu untuk menangkap dinamika isyarat. Hasil penelitian menunjukkan bahwa model GRU lebih efektif dibandingkan LSTM dalam mempelajari pola temporal, sekaligus mengindikasikan bahwa pemodelan urutan gerakan memiliki peran penting dalam meningkatkan performa pengenalan bahasa isyarat dinamis.

Seiring berkembangnya pendekatan berbasis temporal, beberapa penelitian mulai mengombinasikan informasi spasial dan temporal secara lebih terstruktur. Penelitian berbasis video oleh penulis pada tahun 2024 mengusulkan integrasi ResNet sebagai ekstraktor fitur spasial dan LSTM sebagai pemodel temporal untuk pengenalan bahasa isyarat dinamis. Pendekatan ini memisahkan proses ekstraksi fitur visual dari pembelajaran urutan waktu, sehingga memungkinkan model menangkap representasi spasial yang lebih kaya sebelum dianalisis secara temporal. Hasil evaluasi menunjukkan bahwa strategi penggabungan ini mampu meningkatkan akurasi secara signifikan dibandingkan metode konvensional, namun tetap bergantung pada pemrosesan video penuh yang memerlukan sumber daya komputasi relatif besar.

Keterbatasan komputasi pada pendekatan berbasis video mendorong munculnya penelitian yang berfokus pada representasi gerakan tingkat tinggi, salah satunya melalui data pose. Penelitian ini mengkaji pengenalan bahasa isyarat terisolasi dengan memanfaatkan koordinat pose yang dinormalisasi sebagai representasi utama gerakan. Menggunakan Bidirectional LSTM untuk memodelkan dinamika temporal, pendekatan ini mampu mengurangi sensitivitas terhadap latar belakang dan pencahayaan yang sering menjadi kendala pada model berbasis piksel. Hasil penelitian menunjukkan bahwa pendekatan pose-based menawarkan efisiensi komputasi yang lebih baik, meskipun performanya masih sangat bergantung pada ketersediaan dan keberagaman data pelatihan.

Selain representasi pose global, penelitian lain mulai mengeksplorasi detail spasial tingkat mikro yang berperan penting dalam membedakan makna isyarat. Penelitian ini memfokuskan pengenalan bahasa isyarat terisolasi pada konfigurasi dan pergerakan jari dengan memanfaatkan landmark MediaPipe. Pendekatan multisaluran yang memisahkan representasi setiap jari terbukti efektif dalam mengatasi masalah tumpang tindih dan kehilangan informasi

visual. Temuan ini menunjukkan bahwa eksploitasi fitur spasial yang lebih detail dapat meningkatkan akurasi secara signifikan, meskipun berdampak pada meningkatnya kompleksitas dan waktu komputasi.

Berbeda dari pendekatan yang memisahkan atau menggabungkan modul spasial dan temporal secara eksplisit, penelitian lain mengusulkan arsitektur yang lebih sederhana dan seragam. Melalui Fully 2D Convolutional Network, penelitian ini mengintegrasikan informasi temporal ke dalam representasi spasial menggunakan mekanisme splicing sehingga dapat diproses sepenuhnya oleh CNN. Pendekatan ini menghilangkan ketergantungan pada model sekuensial seperti LSTM atau Transformer, sekaligus mempertahankan performa kompetitif pada pengenalan bahasa isyarat berkelanjutan. Hasil tersebut menunjukkan bahwa pemodelan spasio-temporal tidak selalu harus kompleks untuk mencapai kinerja yang baik, membuka peluang eksplorasi arsitektur yang lebih efisien.

Penelitian-penelitian yang menjadi referensi penulis dijabarkan pada Tabel 2.1.

Tabel 2.1 Literasi Penelitian Terdahulu

No	Penulis [Tahun] [Judul]	Permasalahan	Metode	Hasil
1.	Yoses Dwi Maheswara, M.Abid Al- Sulthon , Pradayan Adhimas Wicaksono, Khilda Afifah, dan Novi Prihatiningrum [2023] [<i>Real- Time BISINDO Sign Language Recognition: A Dynamic Approach with GRU and LSTM Models Leveraging MediaPipe</i>] [11]	Pendekatan statis kurang mampu menangkap dinamika gerakan BISINDO secara <i>real-time</i> .	Ekstraksi <i>landmarks</i> MediaPipe <i>Holistic</i> dengan pemodelan temporal menggunakan LSTM dan GRU.	Model GRU mencapai performa terbaik dengan akurasi <i>real-time</i> hingga 83% pada kombinasi <i>landmark</i> tanpa wajah.

No	Penulis [Tahun] [Judul]	Permasalahan	Metode	Hasil
2.	Jiayu Huang dan VarinChouvatut [2024][<i>Video-Based Sign Language Recognition via ResNet and LSTM Network</i>] [24]	Ekstraksi fitur spasio-temporal video sulit dilakukan secara efisien dengan model CNN konvensional.	Arsitektur hibrida ResNet-18 sebagai ekstraktor spasial dan LSTM untuk pemodelan temporal.	Mencapai akurasi 86,25% dan mengungguli beberapa model video-based lainnya.
3.	Daniel Perkins, Davis Hunter, Dhrumil Patel, dan Galen Flanagan [2025] [<i>Isolated Sign Language Recognition with Segmentation and Pose Estimation</i>]	Model berbasis video sulit melakukan generalisasi akibat gangguan latar dan pencahayaan.	Integrasi estimasi pose, segmentasi, dan Bi-LSTM dengan Transformer berbasis pose.	Bi-LSTM dengan koordinat pose yang dinormalisasi mencapai performa tinggi sebesar 68,5%.

No	Penulis [Tahun] [Judul]	Permasalahan	Metode	Hasil
4.	Ali Akdag dan Ã–mer Kaan Baykan [2024] [<i>Multi-Stream Isolated Sign Language Recognition Based on Finger Features Derived from Pose Data</i>]	Detail konfigurasi dan gerakan jari sering diabaikan dalam pengenalan bahasa isyarat.	Pendekatan <i>multi-stream</i> landmark jari dengan MobileNetV2, PCA, dan SVM.	Akurasi tinggi hingga 99,78% pada dataset LSA64.
5.	Qidan Zhu, Jing Li, Fei Yuan dan Quan Gan [2023] [<i>Fully 2D Convolutional Network for Continuous Sign Language Recognition</i>]	Model <i>hybrid</i> spasio-temporal memiliki kompleksitas tinggi dan ketergantungan arsitektur sekuensial.	F2DCNet berbasis 2D CNN murni dengan penggabungan fitur temporal dalam representasi input.	Mencapai <i>Word Error Rate</i> (WER) terendah hingga 20,0% pada dataset skala besar.

Berdasarkan tinjauan terhadap berbagai penelitian terdahulu, terlihat bahwa pengenalan bahasa isyarat umumnya masih bergantung pada pemodelan temporal eksplisit melalui arsitektur sekuensial seperti LSTM, GRU, Transformer, maupun pendekatan berbasis 3D CNN yang menuntut kompleksitas komputasi tinggi. Pendekatan berbasis video RGB menawarkan representasi visual yang kaya, namun sensitif terhadap gangguan latar belakang,

pencapaian, serta kurang efisien untuk diterapkan pada sistem dengan keterbatasan sumber daya. Alternatif berbasis pose dan landmark telah menunjukkan potensi efisiensi yang lebih baik, namun sebagian besar penelitian masih memisahkan pemodelan spasial dan temporal ke dalam modul arsitektur yang berbeda. Celah penelitian muncul pada minimnya eksplorasi pendekatan yang mampu mengintegrasikan informasi temporal secara implisit ke dalam representasi spasial, sehingga memungkinkan penggunaan arsitektur CNN dua dimensi murni tanpa ketergantungan pada mekanisme temporal eksplisit.

Menjawab celah tersebut, penelitian ini mengusulkan pendekatan klasifikasi Isolated Bahasa Isyarat Indonesia (BISINDO) dengan memanfaatkan ResNet-2D berbasis representasi spasial landmark multichannel. Data video tidak diproses sebagai citra RGB, melainkan ditransformasikan menjadi pseudo-image dua dimensi yang merepresentasikan landmark tubuh, tangan, dan wajah hasil ekstraksi MediaPipe. Informasi dinamika gerakan antar-frame dikodekan secara implisit melalui kanal fitur $[x, y, dx, dy]$, sehingga aspek temporal tertanam langsung dalam struktur spasial input. Melalui strategi ini, ResNet-2D berfungsi sebagai pemodel spasial murni yang sederhana dan efisien, sekaligus menawarkan alternatif arsitektur yang lebih ringan dan mudah diimplementasikan untuk penerjemahan bahasa isyarat BISINDO berbasis *landmark*.

2.2 Dasar Teori

Bagian ini menguraikan landasan teoretis yang mendukung pelaksanaan penelitian, khususnya konsep-konsep utama yang berkaitan dengan pengenalan bahasa isyarat berbasis visual dan pemodelan pola gerakan manusia. Pembahasan difokuskan pada konsep yang relevan secara langsung dengan pendekatan penelitian, tanpa mengulas aspek linguistik atau teori umum yang tidak berkontribusi terhadap metode yang digunakan. Dasar teori disusun untuk membangun pemahaman konseptual mengenai bagaimana informasi visual dari

bahasa isyarat dapat direpresentasikan dan dipelajari oleh sistem komputasi. Berdasarkan hal tersebut, bagian ini berfungsi sebagai penghubung antara permasalahan penelitian dan metode yang diusulkan.

2.2.1 Bahasa Isyarat Indonesia (BISINDO)


Bahasa Isyarat Indonesia (BISINDO) merupakan salah satu bahasa isyarat yang digunakan di Indonesia dan lebih umum digunakan dalam komunitas Tuli [5]. BISINDO berkembang secara alami dalam lingkungan sosial masyarakat Tuli Indonesia dan telah digunakan sejak sebelum masa kemerdekaan [1]. Berbeda dengan Sistem Bahasa Isyarat Indonesia (SIBI) yang disusun secara formal dengan mengadopsi struktur bahasa lisan, BISINDO memiliki susunan kata dan pola ekspresi yang lebih bebas serta kontekstual. Perbedaan ini menyebabkan BISINDO tidak selalu mengikuti tata bahasa Indonesia secara langsung, melainkan memanfaatkan kombinasi gerakan tangan, orientasi tubuh, serta ekspresi non-manual untuk menyampaikan makna [25]. Karakteristik visual dan gestural tersebut menjadikan BISINDO sangat bergantung pada pola gerakan tubuh, wajah, dan tangan, sehingga dapat dipandang sebagai permasalahan pengenalan gerakan berbasis visual.

2.2.2 *Sign Language Recognition* (SLR)

Sign Language Recognition (SLR) merupakan bidang penelitian dalam visi komputer yang bertujuan untuk mengenali dan menginterpretasikan bahasa isyarat berdasarkan informasi visual yang diperoleh dari gerakan manusia. Bahasa isyarat dipandang sebagai bahasa visual-gestural yang memanfaatkan kombinasi gerakan tangan, orientasi tubuh, lokasi artikulasi, serta ekspresi non-manual seperti gerakan wajah dan kepala [26]. Karakteristik visual dan multimodal tersebut menjadikan SLR sebagai permasalahan pengenalan pola yang kompleks karena mengandung variasi spasial dan temporal yang tinggi. Pendekatan modern dalam SLR didominasi oleh metode berbasis visi komputer

dan *deep learning* yang memproses data citra maupun video secara langsung [27].

Pendekatan SLR dapat diklasifikasikan berdasarkan beberapa aspek utama, meliputi jenis fitur yang digunakan, modalitas input, serta tingkat kompleksitas tugas pengenalan [26]. Modalitas input visual yang umum digunakan mencakup citra RGB, data kedalaman (*depth*), serta representasi rangka tubuh manusia atau *skeleton*. Data tersebut dapat berasal dari citra statis maupun video dinamis, tergantung pada karakteristik isyarat yang dianalisis. Klasifikasi ini berperan penting dalam menentukan strategi representasi data dan pemilihan arsitektur model yang sesuai. Berikut adalah ilustrasi konsep yang digunakan seperti pada Gambar 2.1.



Gambar 2.1 Taksonomi pendekatan *deep learning* dalam SLR

Sumber: diadaptasi dari Rastgoo et al. [26]

2.2.3 *Isolated Sign Language Recognition*

Isolated Sign Language Recognition (ISLR) merupakan salah satu cabang dari SLR yang berfokus pada pengenalan satu unit isyarat secara terpisah tanpa mempertimbangkan keterkaitan antar-isyarat dalam suatu rangkaian kalimat. Setiap sampel input pada ISLR merepresentasikan satu isyarat tunggal dengan batas awal dan akhir yang telah ditentukan secara eksplisit [26]. Karakteristik

tersebut memungkinkan proses pengenalan difokuskan pada pola gerakan inti dari suatu isyarat. Pendekatan ini banyak digunakan sebagai tahap awal penelitian untuk mengevaluasi efektivitas representasi data dan arsitektur model secara terkontrol [27].

Perbedaan mendasar antara ISLR dan *Continuous Sign Language Recognition* terletak pada bentuk keluaran yang dihasilkan oleh sistem. Pendekatan ISLR menghasilkan satu label kelas yang merepresentasikan satu isyarat, sedangkan pendekatan berkelanjutan menghasilkan urutan label atau transkripsi kalimat isyarat [26]. Kebutuhan untuk memodelkan dependensi temporal jangka panjang pada CSLR menyebabkan kompleksitas pemodelannya menjadi lebih tinggi. Kondisi tersebut menjadikan ISLR lebih sesuai untuk penelitian yang berfokus pada analisis representasi data dan evaluasi arsitektur model secara langsung.

Pendekatan ISLR memungkinkan penggunaan representasi input yang lebih terkontrol tanpa memerlukan pemodelan temporal eksplisit melalui arsitektur sekuensial. Representasi spasial dua dimensi yang menyusun data temporal ke dalam struktur terorganisasi memungkinkan pemanfaatan model CNN dua dimensi untuk pengenalan pola gerakan [26]. Strategi ini sejalan dengan pendekatan penelitian yang mengeksplorasi kemampuan model spasial murni dalam menangkap dinamika gerakan bahasa isyarat. Berdasarkan karakteristik tersebut, penelitian ini difokuskan pada skema *Isolated Sign Language Recognition* untuk mengevaluasi efektivitas representasi spasial dan arsitektur model secara terkontrol.


2.2.4 MediaPipe Holistic

MediaPipe Holistic merupakan solusi visi komputer berbasis *framework* MediaPipe yang dirancang untuk melakukan ekstraksi landmark tubuh manusia secara terintegrasi dari data visual. Sistem ini mampu mendeteksi dan melacak beberapa komponen utama tubuh manusia, meliputi wajah, tangan,

dan pose tubuh dalam satu pipeline pemrosesan terpadu [28]. Pendekatan ini memungkinkan analisis gerak manusia dilakukan secara menyeluruh tanpa memerlukan pemisahan model untuk setiap bagian tubuh. Karakteristik tersebut menjadikan MediaPipe Holistic sesuai untuk aplikasi analisis gerakan berbasis video secara real-time.


MediaPipe dikembangkan sebagai *framework* lintas platform dan bersifat sumber terbuka yang mendukung pemrosesan data streaming seperti video secara efisien. Arsitektur MediaPipe disusun dalam bentuk graf komputasi modular yang terdiri atas komponen-komponen bernama *Calculator*. Struktur ini memungkinkan penyusunan pipeline persepsi yang fleksibel dan dapat disesuaikan dengan kebutuhan aplikasi [28]. Implementasi inti MediaPipe menggunakan bahasa C++ untuk menjamin performa tinggi dan efisiensi memori. Lapisan antarmuka tambahan disediakan untuk bahasa Python dan JavaScript sehingga integrasi pada berbagai platform dapat dilakukan secara cepat.

MediaPipe Holistic menghasilkan representasi *landmark* dalam bentuk koordinat spasial yang merepresentasikan titik-titik kunci pada tubuh manusia. *Landmark* pose tubuh direpresentasikan oleh 33 titik kunci yang mencakup kepala, badan, lengan, dan kaki, masing-masing disertai indeks numerik yang konsisten [29]. Informasi ini memungkinkan pemodelan struktur tubuh dan hubungan antarbagian tubuh secara eksplisit. Representasi *landmark* tersebut menjadi dasar bagi analisis gerakan manusia berbasis data terstruktur. Gambar 2.2 di bawah ini memperlihatkan ilustrasi dari konsep *landmark pose*

Gambar 2.2 Diagram 33 *Landmark MediaPipe Pose*

Sumber: ai.google.dev dan [30]

Selain pose tubuh, MediaPipe Holistic juga menyediakan *landmark* tangan dan wajah untuk menangkap detail gerakan serta ekspresi non-manual. *Landmark* tangan direpresentasikan oleh 21 titik kunci pada setiap tangan yang mencerminkan struktur jari dan telapak secara rinci, sehingga mampu menggambarkan konfigurasi dan dinamika gerakan tangan secara presisi [29]. *Landmark* wajah direpresentasikan oleh 468 titik kunci yang mencakup kontur wajah, mata, hidung, dan mulut, sehingga memungkinkan analisis ekspresi wajah sebagai komponen non-manual dalam bahasa isyarat [29]. Representasi terperinci ini memungkinkan analisis koordinasi gerakan tangan dan ekspresi wajah dilakukan secara bersamaan dalam satu sistem terintegrasi. Struktur *landmark* tangan yang digunakan oleh MediaPipe Holistic ditunjukkan pada Gambar 2.3.

Gambar 2.3 Ilustrasi 21 titik *landmark* tangan pada MediaPipe

Sumber: Gyamenah et al. [30]

Sebaran *landmark* wajah yang digunakan untuk merepresentasikan ekspresi non-manual ditampilkan pada Gambar 2.4.



Gambar 2.4 Ilustrasi 468 titik *landmark* wajah pada MediaPipe

Sumber: [31]

MediaPipe Holistic menghasilkan keluaran berupa koordinat spasial *landmark* yang merepresentasikan posisi titik-titik kunci tubuh manusia pada setiap frame video. Setiap *landmark* direpresentasikan dalam bentuk koordinat (x, y, z) , di mana komponen x dan y menyatakan posisi relatif terhadap bidang citra, sedangkan komponen z merepresentasikan informasi kedalaman relatif terhadap kamera [29]. Nilai koordinat x dan y dinormalisasi terhadap dimensi citra sehingga bersifat invariant terhadap resolusi video. Representasi terstandarisasi ini memungkinkan data *landmark* digunakan secara konsisten sebagai masukan model pembelajaran.

Informasi koordinat *landmark* yang dihasilkan MediaPipe Holistic bersifat berurutan dan tersinkronisasi antar-frame. Karakteristik ini memungkinkan analisis perubahan posisi titik-titik kunci tubuh manusia dari waktu ke waktu. Komponen koordinat tersebut dapat dimanfaatkan untuk menyusun representasi spasial yang mengenkapsulasi dinamika gerakan tanpa memerlukan pemodelan temporal eksplisit. Oleh karena itu, keluaran *landmark* MediaPipe Holistic relevan sebagai dasar penyusunan representasi spasial multichannel pada penelitian ini.

Keluaran berupa koordinat *landmark* dari MediaPipe Holistic menyediakan data spasial berurutan yang merepresentasikan gerakan tubuh

manusia dari waktu ke waktu. Namun, representasi koordinat mentah tersebut belum secara langsung sesuai untuk diproses oleh arsitektur CNN dua dimensi. Oleh karena itu, diperlukan strategi representasi data yang mampu menyusun informasi spasial dan temporal ke dalam struktur yang kompatibel dengan CNN 2D.

2.2.5 Representasi *Landmark* sebagai Struktur Spasial *Landmark Multichannel*

Pada penelitian ini, data bahasa isyarat yang bersifat berurutan direpresentasikan dalam bentuk struktur spasial agar kompatibel dengan model pembelajaran berbasis spasial. Setiap frame video diekstraksi menjadi sekumpulan titik *landmark* tubuh manusia yang merepresentasikan posisi bagian tubuh pada waktu tertentu. Titik-titik *landmark* tersebut kemudian disusun ke dalam sebuah matriks dua dimensi dengan sumbu waktu dan indeks *landmark*. Penyusunan ini memungkinkan data temporal diperlakukan sebagai representasi spasial yang terorganisasi [26]. Pendekatan ini menekankan penyusunan data pada tingkat representasi, terlepas dari arsitektur pembelajaran yang digunakan pada tahap selanjutnya.

2.2.5.1 Koordinat *Landmark* MediaPipe

Pada praktiknya, koordinat *landmark* yang digunakan sangat bergantung pada metode ekstraksi yang diterapkan. MediaPipe Holistic menghasilkan koordinat *landmark* dalam bentuk (x, y, z) yang merepresentasikan posisi relatif titik kunci tubuh manusia terhadap kamera [29]. Komponen x dan y menyatakan posisi pada bidang citra yang telah dinormalisasi, sedangkan komponen z merepresentasikan informasi kedalaman relatif. Estimasi nilai kedalaman tersebut diperoleh dari kamera monokular sehingga sensitif terhadap sudut pandang dan kondisi pengambilan gambar.

Evaluasi akurasi menunjukkan bahwa nilai z bawaan MediaPipe tidak

selalu stabil dan sering memerlukan koreksi tambahan agar dapat digunakan secara andal [32, 33]. Penelitian lain bahkan menerapkan metode tambahan untuk memperbaiki estimasi kedalaman sebelum digunakan lebih lanjut. Temuan tersebut menunjukkan bahwa pemanfaatan koordinat z memerlukan perlakuan khusus agar tidak memperkenalkan noise pada representasi data. Pertimbangan ini menjadi dasar pemilihan representasi dua dimensi pada penelitian ini.

2.2.5.2 Pengodean Dinamika Gerakan Antar-Frame

Berdasarkan pertimbangan kestabilan koordinat, penelitian ini memfokuskan representasi *landmark* pada komponen dua dimensi (x , y). Informasi dinamika gerakan ditangkap melalui perubahan posisi antar-frame yang direpresentasikan sebagai (dx, dy) . Pendekatan ini memungkinkan pengodean informasi temporal secara implisit tanpa memerlukan pemodelan temporal eksplisit melalui arsitektur sekuensial [23]. Perubahan posisi *landmark* antar-frame dihitung menggunakan Persamaan Rumus 2.1.

$$\begin{aligned} dx_t &= x_t - x_{t-1} \\ dy_t &= y_t - y_{t-1} \end{aligned}$$

Rumus 2.1 Perubahan posisi *landmark* antar-frame

Keterangan:

x_t = koordinat horizontal *landmark* pada frame ke- t

y_t = koordinat vertikal *landmark* pada frame ke- t

dx_t = perubahan koordinat horizontal antar-frame

dy_t = perubahan koordinat vertikal antar-frame

t = indeks frame atau urutan waktu

Persamaan tersebut menunjukkan bahwa perubahan posisi diperoleh dari selisih koordinat *landmark* pada dua frame berurutan. Nilai (dx_t, dy_t) mencerminkan arah dan intensitas gerakan antar-frame. Representasi ini memungkinkan dinamika gerakan ditangkap secara langsung pada level fitur. Setiap *landmark* direpresentasikan menggunakan empat kanal fitur, yaitu $(x, y,$

dx, dy).

2.2.5.3 Struktur Tensor Masukan CNN

Seluruh *landmark* pada setiap frame kemudian disusun menjadi sebuah tensor masukan yang selaras dengan format masukan model konvolusional dua dimensi. Struktur tensor masukan tersebut dapat dinyatakan seperti pada Persamaan Rumus 2.2.

$$\mathbf{X} \in \mathbb{R}^{B \times C \times T \times L}, \quad C = 4$$

Rumus 2.2 Struktur tensor masukan *landmark multichannel*

Keterangan:

B = jumlah sampel dalam satu *batch*

C = jumlah kanal fitur, yaitu 4 (x, y, dx, dy)

T = jumlah frame dalam satu urutan

L = jumlah *landmark*


Struktur tensor tersebut memungkinkan urutan *landmark* diperlakukan sebagai representasi spasial multichannel. Format ini selaras dengan masukan CNN dua dimensi yang memproses data multichannel secara spasial. Konsistensi temporal antar-frame berperan penting dalam mencerminkan pola gerakan manusia secara realistis. Representasi ini memungkinkan CNN dua dimensi mempelajari pola gerakan bahasa isyarat dalam skema *Isolated Sign Language Recognition*. Struktur representasi ini selanjutnya menjadi dasar pemodelan menggunakan arsitektur konvolusional dua dimensi yang dibahas pada bagian berikutnya.

2.2.6 Convolutional Neural Network (CNN) 2D

Convolutional Neural Network (CNN) merupakan arsitektur jaringan saraf yang dirancang untuk mempelajari pola lokal pada data yang memiliki struktur grid teratur [34, 35]. CNN bekerja melalui operasi konvolusi yang menerapkan kernel untuk mengekstraksi fitur dari masukan secara bertahap. Pendekatan

ini memungkinkan pembelajaran fitur dilakukan secara hierarkis dari tingkat sederhana hingga kompleks. Masukan CNN dua dimensi direpresentasikan dalam bentuk tensor berdimensi empat, yaitu (B, C, H, W) , di mana H dan W merepresentasikan dua dimensi spasial data [35].

CNN satu dimensi melakukan konvolusi hanya pada satu sumbu, sedangkan CNN dua dimensi melakukan konvolusi pada dua sumbu secara simultan. Perbedaan ini menjadikan CNN 2D lebih sesuai untuk data yang memiliki keterkaitan spasial dua arah. Karakteristik tersebut memungkinkan CNN 2D digunakan untuk memproses representasi spasial non-citra yang disusun dalam bentuk matriks dua dimensi. Arsitektur dasar CNN dua dimensi sebagai landasan pemodelan ditunjukkan pada Gambar 2.5.



Gambar 2.5 Arsitektur dasar CNN dua dimensi

Sumber: diadaptasi dari LeCun et al. [34]

Operasi konvolusi dua dimensi pada CNN dapat dinyatakan secara matematis seperti pada Persamaan Rumus 2.3.

$$Y(i, j) = \sum_m \sum_n X(i + m, j + n) K(m, n)$$

Rumus 2.3 Operasi konvolusi dua dimensi

Keterangan:

X = data masukan dua dimensi

K = kernel atau filter konvolusi

Y = hasil keluaran konvolusi

i, j = indeks posisi spasial pada keluaran


m, n = indeks kernel konvolusi

Persamaan tersebut menunjukkan bahwa setiap nilai keluaran diperoleh

dari hasil perkalian lokal antara masukan dan kernel. Operasi ini memungkinkan CNN mengekstraksi pola spasial seperti tepi, bentuk, atau hubungan antar-elemen data. Prinsip konvolusi dua dimensi ini menjadi dasar bagi seluruh variasi arsitektur CNN, termasuk jaringan berlapis dalam. Pemahaman konsep konvolusi ini penting sebagai landasan penggunaan CNN dua dimensi pada penelitian ini.

2.2.7 *Residual Network (ResNet)*

Residual Network (ResNet) merupakan arsitektur *Convolutional Neural Network* yang diperkenalkan untuk mengatasi permasalahan degradasi performa pada jaringan berlapis sangat dalam [36]. ResNet memungkinkan pelatihan jaringan dengan kedalaman yang jauh lebih besar dibandingkan CNN konvensional tanpa mengalami penurunan akurasi. Arsitektur ini mempertahankan prinsip dasar konvolusi dua dimensi dengan menambahkan mekanisme koneksi residual untuk menjaga stabilitas pelatihan. Gambaran umum arsitektur ResNet secara keseluruhan ditunjukkan pada Gambar 2.6.




Gambar 2.6 Arsitektur umum *Residual Network (ResNet)*

Sumber: diadaptasi dari He et al. [36]

Komponen utama yang membedakan ResNet dari CNN konvensional adalah keberadaan blok residual. Blok residual memungkinkan informasi

masukannya dilewatkan secara langsung ke lapisan yang lebih dalam melalui jalur pintas (*skip connection*) [36]. Pendekatan ini membantu menjaga aliran gradien selama proses pelatihan jaringan berlapis dalam. Struktur dasar blok residual sebagai unit penyusun ResNet ditunjukkan pada Gambar 2.7.



Gambar 2.7 Struktur blok residual pada *Residual Network* (ResNet)

Sumber: diadaptasi dari He et al. [36]

Blok residual pada ResNet dirancang untuk mempelajari fungsi residual terhadap masukan, bukan pemetaan langsung dari masukan ke keluaran. Keluaran blok residual diperoleh melalui penjumlahan antara masukan awal dan hasil transformasi konvolusi. Struktur ini memungkinkan informasi penting dari lapisan sebelumnya tetap dipertahankan sepanjang jaringan. ResNet tetap menggunakan operasi konvolusi dua dimensi sebagai komponen utama pada setiap blok residual.

ResNet dikembangkan dalam beberapa varian yang dibedakan berdasarkan jumlah lapisan dan struktur blok residual yang digunakan [36]. Perbedaan jumlah lapisan memengaruhi kapasitas representasi dan kompleksitas komputasi jaringan. Varian ResNet yang lebih dalam memiliki kemampuan representasi yang lebih tinggi dengan kebutuhan komputasi yang lebih besar. Ringkasan varian ResNet yang umum digunakan ditunjukkan pada Tabel 2.2.

Tabel 2.2 Perbandingan varian arsitektur *Residual Network*

Varian ResNet	Jumlah Lapisan	Tipe Blok	Karakteristik Utama
ResNet-18	18	<i>Basic Block</i>	Ringan dan efisien
ResNet-34	34	<i>Basic Block</i>	Representasi lebih kaya
ResNet-50	50	<i>Bottleneck Block</i>	Lebih dalam dan efisien
ResNet-101	101	<i>Bottleneck Block</i>	Kapasitas representasi tinggi
ResNet-152	152	<i>Bottleneck Block</i>	Representasi sangat kompleks

Sumber: He et al. [36] dan dokumentasi PyTorch [37]

Implementasi ResNet yang banyak digunakan dalam praktik saat ini merujuk pada dokumentasi resmi PyTorch melalui pustaka *torchvision* [37]. Dokumentasi tersebut menyediakan pembangun model untuk berbagai varian ResNet dengan atau tanpa bobot terlatih. Perbedaan implementasi dicatat pada varian *bottleneck*, di mana proses *downsampling* ditempatkan pada konvolusi 3×3 kedua, berbeda dari makalah asli yang menempatkannya pada konvolusi 1×1 pertama. Varian implementasi ini dikenal sebagai ResNet V1.5 dan dilaporkan memberikan peningkatan akurasi tanpa mengubah prinsip dasar pembelajaran residual.

2.2.8 Modifikasi Input Channel pada CNN

2.2.8.1 CNN Tidak Terbatas pada Input RGB

Convolutional Neural Network (CNN) pada awalnya banyak dikembangkan untuk pemrosesan citra berwarna dengan tiga kanal masukan, yaitu merah, hijau, dan biru (RGB). Pendekatan ini menyebabkan persepsi

umum bahwa CNN hanya dapat digunakan untuk data citra konvensional. Faktanya, secara konseptual CNN tidak bergantung pada makna semantik kanal masukan, melainkan pada struktur spasial dan hubungan lokal antar-elemen data [34]. Setiap kanal masukan diperlakukan sebagai dimensi fitur yang diproses secara simultan melalui operasi konvolusi.

Operasi konvolusi dua dimensi pada CNN didefinisikan untuk bekerja pada tensor masukan dengan jumlah kanal yang bersifat fleksibel. Kernel konvolusi memiliki dimensi yang menyesuaikan jumlah kanal masukan tanpa mengubah prinsip dasar operasinya. Karakteristik ini memungkinkan CNN menerima masukan dengan jumlah kanal lebih dari tiga atau bahkan kurang dari tiga. Oleh karena itu, pembatasan CNN pada input RGB bersifat historis dan aplikatif, bukan batasan teoretis.

2.2.8.2 Penerimaan *Arbitrary Number of Channels*

Secara matematis, masukan CNN dua dimensi direpresentasikan dalam bentuk tensor berdimensi empat, yaitu (B, C, H, W) , di mana C menyatakan jumlah kanal masukan. Nilai C tidak ditentukan secara tetap dan dapat disesuaikan dengan kebutuhan representasi data [35]. Operasi konvolusi dilakukan dengan menjumlahkan hasil perkalian kernel terhadap seluruh kanal masukan pada setiap posisi spasial. Pendekatan ini memastikan bahwa informasi dari seluruh kanal berkontribusi terhadap pembentukan peta fitur keluaran.

Fleksibilitas jumlah kanal masukan memungkinkan CNN digunakan untuk berbagai jenis data non-citra. Contoh kanal non-RGB meliputi peta kedalaman, peta gradien, citra multispektral, serta data berbasis sensor [38]. Dalam konteks data sekuensial, dimensi kanal juga dapat digunakan untuk merepresentasikan fitur yang berbeda pada setiap elemen spasial. Kemampuan ini menjadi dasar teoritis penggunaan CNN pada representasi data multichannel yang tidak berbasis warna.

2.2.8.3 Contoh Penerapan CNN pada Data Non-RGB

Berbagai penelitian menunjukkan keberhasilan CNN dalam memproses data non-RGB melalui modifikasi jumlah kanal masukan. CNN digunakan pada citra kedalaman untuk tugas pengenalan aktivitas dan estimasi pose manusia, di mana satu kanal kedalaman menggantikan tiga kanal warna [39]. Pendekatan serupa diterapkan pada data optikal aliran (*optical flow*), di mana vektor gerak direpresentasikan sebagai kanal masukan terpisah [40]. Hasil penelitian tersebut menunjukkan bahwa CNN mampu mengekstraksi fitur bermakna dari kanal yang tidak merepresentasikan warna.

Penggunaan CNN pada data berbasis *landmark* juga telah dieksplorasi dalam berbagai studi pengenalan gerakan dan bahasa isyarat. Koordinat *landmark* dan fitur turunannya diperlakukan sebagai kanal masukan yang membentuk representasi spasial terstruktur. Pendekatan ini memungkinkan CNN mempelajari pola gerakan tanpa memerlukan citra asli sebagai masukan. Berdasarkan landasan teoretis tersebut, penggunaan kanal masukan (x , y , dx , dy) pada penelitian ini berada dalam kerangka konseptual CNN yang valid.

2.2.9 Metrik Evaluasi Klasifikasi

Evaluasi performa model klasifikasi diperlukan untuk menilai kemampuan sistem dalam mengenali kelas secara benar. Metrik evaluasi memberikan ukuran kuantitatif yang merepresentasikan tingkat ketepatan dan keandalan prediksi model. Pemilihan metrik yang sesuai penting untuk memastikan hasil evaluasi mencerminkan kinerja model secara objektif. Pada penelitian ini, evaluasi dilakukan menggunakan metrik klasifikasi yang umum digunakan pada permasalahan pengenalan pola.

2.2.9.1 Confusion Matrix

Confusion matrix merupakan dasar perhitungan berbagai metrik evaluasi klasifikasi. Matriks ini merepresentasikan hubungan antara label prediksi dan

label sebenarnya. Setiap elemen pada matriks menunjukkan jumlah prediksi benar maupun salah untuk setiap kelas. Komponen utama pada *confusion matrix* meliputi *True Positive*, *True Negative*, *False Positive*, dan *False Negative* [41].

2.2.9.2 Accuracy

Accuracy mengukur proporsi prediksi yang benar terhadap seluruh jumlah data yang diuji. Metrik ini memberikan gambaran umum kinerja model klasifikasi. Nilai *accuracy* tinggi menunjukkan banyak prediksi yang sesuai dengan label sebenarnya. Rumus perhitungan *accuracy* ditunjukkan pada Persamaan Rumus 2.4.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Rumus 2.4 Perhitungan *Accuracy*

dengan keterangan:

TP = jumlah prediksi benar untuk kelas positif (*True Positive*)

TN = jumlah prediksi benar untuk kelas negatif (*True Negative*)

FP = jumlah prediksi salah sebagai kelas positif (*False Positive*)

FN = jumlah prediksi salah sebagai kelas negatif (*False Negative*)

2.2.9.3 Precision

Precision mengukur tingkat ketepatan prediksi positif yang dihasilkan oleh model. Metrik ini menunjukkan seberapa besar proporsi prediksi positif yang benar. Nilai *precision* tinggi menandakan rendahnya tingkat kesalahan prediksi positif. Rumus perhitungan *precision* ditunjukkan pada Persamaan Rumus 2.5.

$$Precision = \frac{TP}{TP + FP}$$

Rumus 2.5 Perhitungan *Precision*

2.2.9.4 *Recall*

Recall mengukur kemampuan model dalam mendeteksi seluruh sampel yang benar-benar termasuk dalam kelas positif. Metrik ini menunjukkan seberapa besar proporsi data positif yang berhasil dikenali oleh model. Nilai *recall* tinggi menandakan sedikit data positif yang terlewatkan. Rumus perhitungan *recall* ditunjukkan pada Persamaan Rumus 2.6.

$$Recall = \frac{TP}{TP + FN}$$

Rumus 2.6 Perhitungan *Recall*

2.2.9.5 *F1-Score*

F1-score merupakan metrik yang menggabungkan *precision* dan *recall* dalam satu nilai harmonik. Metrik ini digunakan untuk menyeimbangkan ketepatan dan kelengkapan prediksi model. *F1-score* relevan pada kondisi ketidakseimbangan jumlah data antar-kelas. Rumus perhitungan *F1-score* ditunjukkan pada Persamaan Rumus 2.7.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$


Rumus 2.7 Perhitungan *F1-score*

BAB III


METODE PENELITIAN

3.1 Alur Penelitian

Pada penelitian ini, alur dirancang untuk memastikan setiap tahapan pemrosesan dilakukan secara sistematis dan efisien. Alur penelitian ini mencerminkan langkah-langkah utama yang dilakukan pada penelitian ini, dapat dilihat pada Gambar 3.1 dan Gambar 3.2.



Gambar 3.1 Tahap Identifikasi Masalah Hingga Rekayasa Fitur



Gambar 3.2 Tahap Penyusunan Tensor Hingga Hasil dan Kesimpulan

3.2 Penjabaran Langkah Penelitian

Untuk memperjelas setiap langkah-langkah yang telah didefinisikan pada Gambar ??, berikut ini akan dijelaskan secara rinci tahapan-tahapan yang dilakukan dalam penelitian ini.

3.2.1 Identifikasi Masalah dan Studi Literatur

3.2.2 Pengumpulan Dataset

Dataset pada penelitian ini diperoleh melalui proses perekaman video bahasa isyarat secara terkontrol. Data dikumpulkan dengan merekam gerakan bahasa isyarat tunggal (*isolated sign*) yang dilakukan oleh subjek penelitian. Setiap isyarat direkam dalam bentuk video berdurasi pendek dengan batas awal

dan akhir yang jelas. Pendekatan ini bertujuan untuk menghasilkan dataset yang sesuai dengan skema *Isolated Sign Language Recognition*.

3.2.3 Akuisisi Video Bahasa Isyarat

3.2.4 Preprocessing Data

Tahap preprocessing bertujuan untuk menyiapkan data video sebelum dilakukan rekayasa fitur dan pemodelan. Preprocessing difokuskan pada penyesuaian format data dan ekstraksi informasi visual awal. Tahapan ini memastikan data berada dalam kondisi yang konsisten dan siap diproses lebih lanjut. Proses preprocessing meliputi penyesuaian resolusi video dan ekstraksi *landmark* tubuh manusia.

3.2.4.1 Augmentasi Resolusi Video

Resolusi video diseragamkan untuk memastikan konsistensi dimensi masukan pada setiap sampel data. Penyesuaian resolusi dilakukan tanpa mengubah rasio aspek video. Langkah ini bertujuan untuk menjaga stabilitas proses ekstraksi *landmark*. Video hasil penyesuaian resolusi digunakan sebagai masukan pada tahap ekstraksi *landmark*.

3.2.4.2 Ekstraksi Landmark MediaPipe Holistic

Ekstraksi *landmark* dilakukan menggunakan MediaPipe Holistic. Model ini menghasilkan *landmark* pose tubuh dan tangan dalam bentuk koordinat dua dimensi. Setiap frame video diproses secara independen untuk memperoleh posisi titik-titik kunci tubuh manusia. Hasil ekstraksi berupa deret *landmark* yang merepresentasikan gerakan bahasa isyarat.

3.2.4.3 Seleksi Landmark

Tidak seluruh *landmark* hasil ekstraksi digunakan pada penelitian ini. Seleksi *landmark* dilakukan untuk memfokuskan representasi pada bagian tubuh yang relevan terhadap bahasa isyarat. Koordinat kedalaman (z) tidak

digunakan karena estimasinya bersifat relatif dan kurang stabil. Proses seleksi bertujuan untuk mengurangi kompleksitas data tanpa menghilangkan informasi gerakan utama.

3.2.5 Rekayasa Fitur (*Feature Engineering*)

3.2.5.1 Perhitungan Perubahan Antar-Frame

Perubahan posisi *landmark* antar-frame dihitung untuk menangkap dinamika gerakan. Perhitungan dilakukan berdasarkan selisih koordinat dua frame berurutan. Pendekatan ini memungkinkan informasi temporal direpresentasikan secara implisit. Rumus perhitungan perubahan antar-frame mengikuti formulasi yang telah dijelaskan pada Bab II.

3.2.5.2 Representasi *Landmark Multichannel*

Sebagai ilustrasi konseptual, Tabel ?? menunjukkan contoh representasi satu titik *landmark* pada dua frame berurutan beserta perubahan posisinya. Nilai numerik pada tabel bersifat ilustratif dan tidak merepresentasikan data eksperimen sebenarnya. Ilustrasi ini bertujuan untuk memberikan gambaran konkret mengenai pembentukan fitur multichannel. Pendekatan ini membantu pembaca memahami konsep representasi tanpa bergantung pada dataset tertentu.

Tabel 3.1 Ilustrasi representasi fitur *landmark multichannel* untuk satu *landmark* sepanjang waktu

Frame	Indeks	Nama <i>Landmark</i>	x	y	dx	dy
$t - 2$	0	Wrist	0.42	0.62	–	–
$t - 1$	0	Wrist	0.45	0.60	0.03	-0.02
t	0	Wrist	0.48	0.58	0.03	-0.02
$t + 1$	0	Wrist	0.50	0.56	0.02	-0.02
$t + 2$	0	Wrist	0.52	0.54	0.02	-0.02

Catatan: Ilustrasi menunjukkan perubahan posisi satu *landmark* (Wrist) pada beberapa frame berurutan.

Setiap *landmark* direpresentasikan menggunakan empat kanal fitur, yaitu

(x, y, dx, dy) . Seluruh *landmark* pada setiap frame disusun secara berurutan membentuk representasi spasial multichannel. Representasi ini memungkinkan data gerakan diproses oleh CNN dua dimensi. Ilustrasi representasi *landmark multichannel* ditunjukkan pada Tabel 3.1.

3.2.6 Penyusunan Tensor Masukan CNN

Representasi *landmark multichannel* selanjutnya disusun ke dalam bentuk tensor masukan CNN. Tensor masukan disusun mengikuti format kanal-terlebih-dahulu (*channel-first*). Struktur tensor disesuaikan dengan arsitektur CNN dua dimensi yang digunakan. Penyusunan tensor ini menjadi penghubung antara tahap rekayasa fitur dan pemodelan.

3.2.7 Konfigurasi Model dan *Hyperparameter*

3.2.7.1 Arsitektur ResNet-2D

3.2.7.2 Modifikasi Input *Channel*

3.2.7.3 Konfigurasi *Hyperparameter*

3.3 Alat dan Bahan

Dalam menjalani penelitian, beberapa alat dan bahan digunakan untuk memastikan penelitian berjalan dengan baik.

3.3.1 Alat

Dalam membuat pengukuran frekuensi denyut nadi non-kontak dalam penelitian, berikut adalah alat-alat yang digunakan:

1. *Visual Studio Code* sebagai *tools* untuk *text editor*.
2. Python versi 3.12.5
3. OpenCV versi 4.10.0.84
4. NumPy versi 2.1.1
5. Mediapipe versi 0.10.14
6. Scipy versi 1.12.0
7. Matplotlib versi 3.8.3

8. Flask versi 3.1.0

3.3.2 Bahan

Dataset yang digunakan pada penelitian ini merupakan dataset

3.4 Metode Evaluasi

Evaluasi performa model dilakukan menggunakan metrik klasifikasi yang telah didefinisikan pada Bab II. Pengujian dilakukan pada data uji yang tidak digunakan selama proses pelatihan. Pendekatan ini bertujuan untuk menilai kemampuan generalisasi model. Hasil evaluasi dianalisis untuk menilai efektivitas pendekatan yang diusulkan.

3.4.1 Metrik Evaluasi

3.4.2 Prosedur Pengujian

3.5 Ilustrasi Proses Pengolahan Data

3.5.1 Ilustrasi Input Video

3.5.2 Ilustrasi Ekstraksi *Landmark*

3.5.3 Ilustrasi Pembentukan Tensor

DAFTAR PUSTAKA

- [1] H. Olivia and F. S. Mulyadi, "Tindakan Komunikatif Komunitas Tuli Dalam Ruang Publik Sunyi Coffee Sebagai Upaya Perjuangan Demokratis," *eJournal Komunikasi*, vol. 13, no. 1, Apr. 2022, 2086-6178.
- [2] V. Verushka. "The International Day of Sign Languages: Nonverbal Communication." Program Studi S-1 Ilmu Komunikasi, Universitas Padjadjaran.
- [3] D. A. Saraswati, V. D. Towidjojo, and Hasanuddin, "Bahasa Isyarat Indonesia (Indonesia Sign Language)," *Jurnal Medical Profession (MedPro)*, vol. 4, no. 1, Feb. 2022.
- [4] C. Nilawaty. "Alasan Insan Tuli Memilih Bahasa Isyarat Bisindo Ketimbang SIBI." Accessed: 2026-01-12.
- [5] A. Lavenia. "Susahnya Jadi Tuli di Indonesia: Minim Akses dan Dihantui Stereotip." Accessed: 2026-01-13.
- [6] D. Arlinta. "Menjembatani Keterbatasan Komunikasi Lewat Aplikasi." Accessed: 2025-01-13.
- [7] A. Pathak, N. Patil, P. Padhy, A. Jadhav, S. Rukhande, and L. Gadhikar, "Real-Time Sign Language to Speech Converter Using OpenCV and MediaPipe," *2025 International Conference on Emerging Systems and Intelligent Computing (ESIC)*, 2025, pp. 32–36.
- [8] J. Kavitha and D. Nagarajan, "Real Time Automated Sign Language Recognition and Transcription with Audio Feedback," *2023 IEEE International Carnahan Conference on Security Technology (ICCST)*, 2023, pp. 1–6.
- [9] A. Anturkar et al., "Real-Time Sign Language to Text Translation Using Deep Learning: A Comparative Study of LSTM and 3D CNN,"

- International Journal of Computer Applications*, vol. 187, no. 55, pp. 31–35, Nov. 2025.
- [10] D. Kumari and R. S. Anand, “Isolated Video-Based Sign Language Recognition Using a Hybrid CNN-LSTM Framework Based on Attention Mechanism,” *Electronics*, vol. 13, no. 7, p. 1229, 2024, 2079-9292.
 - [11] Y. D. Maheswara, M. A. Al-Sulthon, P. A. Wicaksono, K. Afifah, and N. Prihatiningrum, “Real-Time BISINDO Sign Language Recognition: A Dynamic Approach with GRU and LSTM Models Leveraging MediaPipe,” *2023 6th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, 2023, pp. 226–232.
 - [12] W. Utomo, Y. Suhanda, H. Ar-Rasyid, and A. Dharmalau, “Indonesian Language Sign Detection Using Mediapipe with Long Short-Term Memory (LSTM) Algorithm,” *Journal of Information and Web Engineering*, vol. 4, no. 3, pp. 15–25, Oct. 2025.
 - [13] I. V. Lemmuela, M. Ayub, and O. Karnalim, “Dynamic Sign Language Recognition in Bahasa Using MediaPipe, Long Short-Term Memory, and Convolutional Neural Network,” *Journal of Information Systems Engineering and Business Intelligence*, vol. 11, no. 1, pp. 17–29, Mar. 2025, 2443-2555.
 - [14] Y. Zhu et al., *A Comprehensive Study of Deep Video Action Recognition*, 2020. arXiv: [2012.06567](https://arxiv.org/abs/2012.06567) [cs.CV].
 - [15] M. Wani and A. Faridi, “Deep Learning-Based Video Action Recognition: A Review,” *2022 International Conference on Computing, Communication, and Intelligent Systems (ICCCIS)*, Nov. 2022, pp. 243–249.

- [16] F. Gu, M.-H. Chung, M. Chignell, S. Valaee, B. Zhou, and X. Liu, "A Survey on Deep Learning for Human Activity Recognition," *ACM Computing Surveys (CSUR)*, vol. 54, no. 8, Oct. 2021, 0360-0300.
- [17] P. Gong and X. Luo, "A Survey of Video Action Recognition Based on Deep Learning," *Knowledge-Based Systems*, vol. 320, p. 113 594, 2025, 0950-7051.
- [18] M. Sholawati, K. Auliasari, and F. X. Ariwibisono, "Pengembangan Aplikasi Pengenalan Bahasa Isyarat Abjad SIBI Menggunakan Metode Convolutional Neural Network (CNN)," *JATI: Jurnal Teknologi Informasi*, vol. 6, no. 1, Mar. 2022.
- [19] D. Saputra and Y. Hadiwandra, "Klasifikasi Huruf dan Angka dalam Bisindo Menggunakan Metode Convolutional Neural Network," *Indonesian Journal of Informatic Research and Software Engineering (IJIRSE)*, vol. 4, no. 2, Sept. 2024.
- [20] Q. Zhu, J. Li, F. Yuan, and Q. Gan, "Fully 2D Convolutional Network for Continuous Sign Language Recognition," *Fuzzy Systems and Data Mining IX*, A. Tallón-Ballesteros and R. Beltrán-Barba, eds., This article is published online with Open Access by IOS Press and distributed under the terms of the Creative Commons Attribution Non-Commercial License 4.0 (CC BY-NC 4.0), Harbin, China: IOS Press, 2023, p. 244.
- [21] K. Kim, S. N. Gowda, O. M. Aodha, and L. Sevilla-Lara, *Capturing Temporal Information in a Single Frame: Channel Sampling Strategies for Action Recognition*, 2022. arXiv: [2201.10394](https://arxiv.org/abs/2201.10394) [[cs.CV](#)].
- [22] H. Bilen, B. Fernando, E. Gavves, and A. Vedaldi, *Action Recognition with Dynamic Image Networks*, 2017. arXiv: [1612.00738](https://arxiv.org/abs/1612.00738) [[cs.CV](#)].
- [23] L. Wang et al., *Temporal Segment Networks for Action Recognition in Videos*, 2017. arXiv: [1705.02953](https://arxiv.org/abs/1705.02953) [[cs.CV](#)].

- [24] J. Huang and V. Chouvatut, "Video-Based Sign Language Recognition via ResNet and LSTM Network," *J Imaging*, vol. 10, no. 6, p. 149, June 2024.
- [25] Bentara. "SIBI dan BISINDO: Sama atau Beda? Mengenal Perbedaan Dua Bahasa Isyarat di Indonesia."
- [26] R. Rastgoo, K. Kiani, and S. Escalera, "Sign Language Recognition: A Deep Survey," *Expert Systems with Applications*, vol. 164, p. 113 794, 2021, 0957-4174.
- [27] R. H. Shende and N. F. Shaikh, *Machine Learning and Deep Learning Paradigms in Sign Language Recognition for the Hearing Impaired: A Comprehensive Review*, Available at SSRN, 2024.
- [28] M. C. Manullang and G. M. R, *COMPUTERVISION: Panduan Pemula Untuk Penelitian dan Aplikasi Praktis*, Terbitan Pertama, M. C. Manullang, ed. ITERAPress, July 2025, p. 298, ISBN: 978-634-7013-76-7.
- [29] Google. "MediaPipe Holistic Landmarker."
- [30] P. Gyamenah, H. Iyer, H. Jeong, and S. Guo, "CLUMM: Contrastive Learning for Unobtrusive Motion Monitoring," *Sensors*, vol. 25, p. 1048, Feb. 2025.
- [31] H. Komajou. "Mediapipe Landmark Face/Hand/Pose Sequence Number List View."
- [32] S. Dill et al., "Accuracy Evaluation of 3D Pose Reconstruction Algorithms Through Stereo Camera Information Fusion for Physical Exercises with MediaPipe Pose," *Sensors*, vol. 24, no. 23, 2024, 1424-8220.
- [33] Y. Lin, X. Jiao, and L. Zhao, "Detection of 3D Human Posture Based on Improved Mediapipe," *Journal of Computer and Communications*, 2023.

- [34] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-Based Learning Applied to Document Recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998.
- [35] J. Wu, "Introduction to Convolutional Neural Networks," 2017.
- [36] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *arXiv preprint arXiv:1512.03385*, 2016.
- [37] PyTorch Contributors. "ResNet." TorchVision Model Documentation.
- [38] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [39] J. Shotton et al., "Real-Time Human Pose Recognition in Parts from Single Depth Images," *CVPR*, 2011.
- [40] K. Simonyan and A. Zisserman, "Two-Stream Convolutional Networks for Action Recognition in Videos," *NIPS*, 2014.
- [41] D. M. W. Powers, "Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation," *Journal of Machine Learning Technologies*, 2011.

LAMPIRAN